Rompere il Codice

DISIM UnivAQ

29 Settembre 2023

Problema

Disclaimer: Questo problema si ispira a quelli del concorso non competitivo Bebras, organizzato dal Dipartimento di Informatica dell'Università degli Studi di Milano.

In un **codice prefisso**, ogni lettera viene trasformata in una sequenza di uno o più simboli (detta codifica) in maniera tale che nessuna codifica inizi con un'altra codifica. Per esempio, se la lettera "A" fosse codificata con la sequenza "12", la lettera "B" potrebbe essere codificata con "2" ("12" non inizia con "2"). In tal caso la lettera "C" potrebbe essere codificata con "11" (né "12" né "2" iniziano con "11" e, viceversa, "11" non inizia né con "12", né con "2"), ma non con "21" (inizia con "2"), con "121" (inizia con "12"), né con "1" (è la parte iniziale di "12").

Quella che segue è una codifica prefissa della stringa "**STREET-SCIENCE**" (virgolette escluse) che utilizza i 4 caratteri dell'insieme {"0","1","2","3"}:

0102031102000010010021003001 1

Dividete la stringa precedente con delle virgole, in modo da separare la codifica di ogni lettera. **(1 punto)**

Formato della Risposta

La risposta deve essere inserita sulla piattaforma di correzione sotto forma di **stringa**: inserite i caratteri virgola nella stringa data per dividerla e riportate quanto ottenuto.
NON devono esserci spazi né altri caratteri, e non sono validi separatori diversi dalla virgola. **NON** è garantito che risposte corrette ma non conformi a quanto specificato vengano considerate giuste.

Soluzione

Si potrebbe risolvere il problema utilizzando **un approccio esaustivo**: siccome siamo sicuri che il messaggio codificato cominci con la codifica della lettera "s", possiamo tentare tutte le sue possibili codifiche utilizzando i primi caratteri del codificato e passare alla lettera successiva. Ad esempio:

- "s" = "0": questo significa risolvere il problema per la stringa "treet-[0]cience" = "10203110200001001002100300 11";
- "s" = "01": questo significa risolvere il problema per la stringa "treet-[01]cience" = "0203110200001001002100300 11";
- "s" = "010": questo significa risolvere il problema per la stringa "treet-[010]cience" = "2031102000010010021003001 1".

E così via provando per ognuno dei casi la possibile codifica della "t", poi della "r" ecc.

Un approccio più furbo potrebbe essere quello di sfruttare i pattern e le numerosità dei caratteri per limitare i casi possibili.

Notiamo che la frase da codificare termina con "e", il carattere più comune. Possiamo lavorare a ritroso (da destra a sinistra) per escludere alcune codifiche:

- "11": impossibile, perché le occorrenze di "11" dovrebbero essere almeno quante le "e";
- "011" e stringhe più lunghe contenenti "11": impossibili per lo stesso motivo.

L'unica codifica possibile per "e" è dunque "1"!

Il nostro problema si riduce a risolvere:

Originale	**Codifica**
street-scienc	01020311020000100100210030 01
e	1

Notiamo che la "e" si ripete in caratteri adiacenti nella parola "street" e c'è un solo punto dove si ripetono due "1", quindi:

Originale	**Codifica**
str	010203
ee	1,1
t-scienc	02000010010021003001
e	1

La "s" non può essere codificata con 0, altrimenti la "t" di "t-science" comincerebbe con la codifica di "s". Non può essere codificata con "010", altrimenti la "t" di "str" e quella di "t-science" comincerebbero con caratteri diversi ("2" o "0"). Se fosse codificata con "0102", la "t" dovrebbe per forza essere "0" e la "r" essere "3". Ma allora "t" sarebbe codificata con un prefisso della codifica di "s", violando la definizione. L'unica soluzione possibile è che "s" sia codificata con "01":

Originale	**Codifica**
s	01
tr	0203
ee	1,1
t-scienc	02000010010021003001
e	1

Analizzando la stringa "tr", notiamo che "t" non può essere "0", quindi la scelta è tra "02" e "020" entrambi plausibili.

Se "t" = "02"

Originale	**Codifica**
street	01,02,03,1,1,02
-scienc	000010010021003001
e	1

Considerando la codifica della "s" (secondo carattere di "-scienc"), "-" può essere codificato con "000" o con "000010"
<u>Nel primo caso</u> si ha:

Originale	**Codifica**
street-s	01,02,03,1,1,02,000,01
cienc	0010021003001
e	1

Questo implicherebbe che la "c" è l'unica sequenza plausibile con cui inizia e termina "0010021003001", ovvero "001".
<u>Nel secondo caso</u>:

Originale	**Codifica**
street-s	01,02,03,1,1,02,000010,01
cienc	0021003001
e	1

Ma in questo caso la "c" non avrebbe nessuna codifica valida! Infatti, nessuna sottostringa compare all'inizio e alla fine di "0021003001", se non se stessa.

Ripartiamo allora da

Originale	**Codifica**
street-sc	01,02,03,1,1,02,000,01,001
ien	0021003
ce	001,1

A questo punto l'unico "1" in "0021003" non può che essere una "e" e quindi "i" = "002" e "n" = "003":

Originale	**Codifica**
street-science	01,02,03,1,1,02,000,01,001,002,1,003,001,1

Abbiamo trovato una soluzione possibile, ma è unica? In generale ciò non è garantito, nel nostro caso abbiamo supposto "t" = "02". Per essere sicuri dell'unicità dobbiamo controllare che l'altra possibile codifica porti ad una situazione impossibile.

Se "t" = "020"

Originale	**Codifica**
street	01,020,3,1,1,020
-scienc	00010010021003001
e	1

Considerando la codifica della "s" (secondo carattere di "-scienc"), "-" può essere codificato con "00" o con "00010"
Nel primo caso:

Originale	**Codifica**
street-s	01,020,3,1,1,020,00,01
cienc	0010010021003001
e	1

La "c" in apertura e chiusura della sottostringa "cienc" avrebbe codifica "001", di cui "-" = "00" è prefisso!
Nel secondo caso:

Originale	**Codifica**
street-s	01,020,3,1,1,020,00010,01
cienc	0010010021003001
e	1

E:

Originale	**Codifica**
street-sc	01,020,3,1,1,020,00010,01,001
ien	0010021003
ce	001,1

Ma questo renderebbe invalida ogni codifica per la "i": "0", "00", "001" sono prefissi di o coincidono con altre codifiche. Ogni codifica più lunga avrebbe la codifica della "c" come prefisso. **Nessuna altra soluzione oltre quella trovata precedentemente è dunque ammissibile!**